

LAPORAN UJIAN AKHIR SEMESTER (UAS)

Analisis Sentimen Berbasis Aspek (ABSA) dan Named Entity Recognition (NER) pada Opini Masyarakat Terkait Program Makan Bergizi Gratis Menggunakan Pendekatan Multi-Model



Disusun Oleh:

Nanditho Wahyu Christian

A11.2021.13649

PROGRAM STUDI TEKNIK INFORMATIKA

FAKULTAS ILMU KOMPUTER

UNIVERSITAS DIAN NUSWANTORO

2026

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Dinamika kebijakan publik di Indonesia kerap memicu beragam reaksi dari masyarakat luas di media sosial. Salah satu program yang saat ini banyak diperbincangkan adalah program Makan Bergizi Gratis (MBG). Opini publik yang muncul di platform seperti YouTube terpecah menjadi berbagai sentimen, mulai dari dukungan penuh terhadap program, keraguan terhadap efektivitas distribusi, hingga kritik tajam terkait pengelolaan anggaran. Volume komentar yang besar dan tidak terstruktur membuat analisis manual menjadi tidak efisien dan rentan bias subjektif dari penganalisis.

Oleh karena itu, pendekatan komputasional berbasis Pemrosesan Bahasa Alami (Natural Language Processing/NLP) diperlukan untuk memetakan opini publik secara otomatis, terukur, dan dapat direproduksi. Proyek ini secara sengaja menggunakan data mentah (raw) hasil crawling dari Kaggle tanpa melalui proses kurasi label manual, dengan tujuan menguji bagaimana algoritma pembelajaran mesin bekerja pada kondisi data dunia nyata (in-the-wild) yang secara inheren mengandung derau label (label noise) akibat subjektivitas anotator asli dataset.

1.2 Rumusan Masalah

Berdasarkan latar belakang tersebut, permasalahan yang diangkat pada penelitian ini adalah sebagai berikut:

1. Bagaimana mengekstraksi entitas spesifik (Aspek, Tokoh, Organisasi, Lokasi) dari teks ulasan yang tidak terstruktur menggunakan pendekatan Rule-Based Named Entity Recognition (NER)?
2. Algoritma supervised learning manakah yang paling tangguh (robust) dalam menangani klasifikasi sentimen berbasis aspek pada dataset dunia nyata yang masih mengandung derau label (noise label)?

1.3 Tujuan Penelitian

Tujuan dari proyek ini adalah membangun sebuah sistem yang mampu:

3. Melakukan pra-pemrosesan teks tingkat lanjut, termasuk normalisasi kata tidak baku menggunakan Minimum Edit Distance, serta ekstraksi entitas menggunakan pendekatan Rule-Based Named Entity Recognition (NER).
4. Membandingkan performa prediksi dari empat algoritma klasifikasi (Random Forest, Multinomial Naive Bayes, Logistic Regression, dan Support Vector Machine) secara komparatif pada data yang tidak dikurasi.
5. Menjadikan hasil komparasi ini sebagai landasan pengujian kualitas data sentimen publik, khususnya dalam mengidentifikasi sejauh mana label noise memengaruhi performa model.

1.4 Keterkaitan dengan Pemrosesan Bahasa Alami (PBA) Berbasis Teks

Proyek ini merupakan implementasi langsung dari beberapa pilar utama teori Pemrosesan Bahasa Alami (PBA) yang diterapkan secara paralel dalam satu pipeline, yaitu: (1) Sequence Labeling, melalui implementasi NER dan skema BIO Tagging; (2) pengukuran similaritas kalimat, melalui Cosine Similarity pada representasi TF-IDF; dan (3) Text Classification, yaitu klasifikasi sentimen menggunakan algoritma pembelajaran mesin terawasi (supervised machine learning).

BAB 2

TINJAUAN KONSEP

2.1 Preprocessing Teks dan Minimum Edit Distance

Preprocessing merupakan tahap krusial untuk membersihkan data teks dari noise sebelum masuk ke tahap pemodelan. Tahapan ini pada penelitian ini mencakup Case Folding, Punctuation Removal menggunakan pola Regular Expression (Regex), Stopword Removal, dan Stemming menggunakan pustaka Sastrawi. Selain itu, konsep Minimum Edit Distance (jarak Levenshtein) digunakan sebagai landasan teori untuk mengukur jumlah operasi minimal (penyisipan, penghapusan, penggantian karakter) yang dibutuhkan untuk mengubah kata yang salah ketik (typo) menjadi kata baku yang dituju.

2.2 TF-IDF dan N-Gram

Term Frequency-Inverse Document Frequency (TF-IDF) merupakan metode representasi teks ke dalam bentuk vektor numerik berdimensi tinggi. Komponen Term Frequency (TF) menghitung frekuensi kemunculan sebuah kata pada suatu dokumen, sedangkan Inverse Document Frequency (IDF) memberikan bobot lebih rendah pada kata-kata yang muncul di hampir seluruh dokumen (kata umum). Penggunaan kombinasi unigram dan bigram (n-gram range 1-2) memungkinkan model menangkap konteks urutan dua kata secara bersamaan, sehingga frasa bermakna ganda atau bentuk negasi (misalnya "tidak enak") dapat direpresentasikan dengan lebih akurat dibandingkan hanya menggunakan representasi kata tunggal.

2.3 Supervised Learning dan Ketahanan terhadap Noise Label

Penelitian ini menguji dan membandingkan empat algoritma supervised learning untuk tugas klasifikasi sentimen:

- Random Forest: metode ensemble learning berbasis kumpulan pohon keputusan (decision trees) yang mengambil keputusan akhir melalui mekanisme voting mayoritas antar pohon. Karakteristik ensemble dan proses bootstrap aggregating (bagging) pada Random Forest secara teoritis membuatnya lebih toleran terhadap kesalahan label pada sebagian kecil data latih, karena kesalahan pada satu pohon cenderung tidak mendominasi keputusan gabungan (Breiman, 2001).
- Multinomial Naive Bayes (MNB): model probabilistik berbasis Teorema Bayes yang mengasumsikan independensi antar fitur kata.
- Logistic Regression: model klasifikasi linier probabilistik yang mengestimasi peluang kelas menggunakan fungsi logistik/softmax.
- Support Vector Machine (SVM): algoritma yang mencari hyperplane pemisah dengan margin maksimal antar kelas. SVM dengan kernel linear umumnya sangat kuat pada data teks yang bersih, namun cenderung lebih sensitif terhadap titik-titik data pada batas kelas (support vectors) yang berasal dari label yang keliru atau tumpang tindih, karena posisi hyperplane sangat dipengaruhi oleh titik-titik data di sekitar margin.

2.4 Evaluasi Model

Kinerja setiap model klasifikasi diukur menggunakan Confusion Matrix, yang selanjutnya digunakan untuk menghitung metrik Accuracy, Precision, Recall, dan F1-Score pada masing-masing kelas sentimen (Negatif, Netral, Positif).

2.5 Named Entity Recognition (NER) dan BIO Tagging

Named Entity Recognition (NER) adalah tugas NLP yang bertujuan mengklasifikasikan token/kata ke dalam kategori entitas tertentu, seperti nama tokoh, organisasi, atau lokasi. BIO Tagging (Begin, Inside, Outside) merupakan skema pelabelan standar untuk tugas sequence labeling, di mana tag B menandai token pertama dari sebuah entitas, tag I menandai token lanjutan dari entitas yang sama, dan tag O menandai token yang bukan bagian dari entitas apa pun.

BAB 3

DATASET

3.1 Sumber dan Cara Pengumpulan Data

Data yang digunakan dalam penelitian ini merupakan dataset sekunder yang diunduh langsung dari repositori Kaggle berjudul "Indonesian Youtube Comments: MBG Program". Dataset ini berisi hasil penarikan (crawling) 5.035 komentar pengguna YouTube Indonesia yang memberikan opini terkait kebijakan Makan Bergizi Gratis. Dataset ini terdiri dari dataset mentah, serta dataset yang sudah dilakukan pembersihan dan pelabelan pada fitur sentiment.

3.2 Manajemen Kualitas Data dan Jumlah Data

Data yang digunakan pada penelitian ini adalah dataset mentah yang belum diolah oleh author. Berbeda dengan skenario ideal penelitian NLP pada umumnya, penelitian ini secara sengaja tidak melakukan kurasi label manual. Keputusan ini diambil untuk menguji ketahanan algoritma terhadap kondisi dataset in-the-wild yang rentan terhadap pelabelan subjektif oleh pembuat dataset asli. Total data mentah yang berhasil dimuat berjumlah 5.035 baris komentar. Setelah melalui tahap preprocessing dan penggabungan dengan label sentimen, data kemudian disampling secara stratified untuk mengatasi ketidakseimbangan kelas (class imbalance), sehingga menghasilkan subset data berlabel sebanyak 450 baris yang digunakan untuk tahap pemodelan.

3.3 Distribusi Label Sentimen

Data hasil stratified sampling diatur menjadi proporsi seimbang dan diekspor ke berkas `absa_dataset_sampled.csv` dengan distribusi sebagai berikut:

- Sentimen Negatif: 150 data
- Sentimen Netral: 150 data
- Sentimen Positif: 150 data

3.4 Skema Label Entitas (NER)

Sistem Rule-Based NER pada penelitian ini dirancang menggunakan empat kamus (dictionary) kategori entitas utama, yaitu ASPECT (mencakup kata kunci seperti anggaran, menu, gizi, distribusi), PER (tokoh/nama individu), ORG (organisasi seperti pemerintah, sekolah, TNI/Polri), dan LOC (lokasi geografis seperti Papua, desa, Jakarta).

3.5 Etika Penggunaan Data

Mengingat data berasal dari platform media sosial publik, analisis pada penelitian ini hanya berfokus pada struktur teks linguistik untuk kepentingan riset akademik. Identitas spesifik seperti URL dan mention akun dihapus menggunakan Regex sejak tahap awal preprocessing untuk menjaga anonimitas pengguna yang berkomentar.

BAB 4 METODOLOGI

4.1 Alur Preprocessing dan Edit Distance

Teks komentar dibersihkan menggunakan empat fungsi Regular Expression, yaitu penghapusan tag HTML, penghapusan URL/tautan, penghapusan mention (@) dan hashtag (#), serta penghapusan karakter non-alfabet. Selanjutnya dilakukan Case Folding, normalisasi kata slang/singkatan menggunakan kamus normalisasi (contoh: "yg" menjadi "yang", "tp" menjadi "tapi", "mbg" menjadi "makan bergizi gratis"), Stopword Removal, dan Stemming menggunakan pustaka Sastrawi.

Sebagai bukti penerapan konsep Minimum Edit Distance, dilakukan pengujian jarak modifikasi dari kata salah ketik "nggaran" menuju kata baku "anggaran", yang menghasilkan jarak edit sebesar 1 (satu) operasi penyisipan karakter. Proses stemming pada 5.035 baris

data juga dipercepat menggunakan teknik Dictionary Caching, yaitu menyimpan hasil stemming kata yang sudah pernah diproses ke dalam memori (cache) agar tidak perlu dihitung ulang, sehingga secara signifikan mengurangi redundansi komputasi Sastrawi pada kata yang berulang.

4.2 Analisis Kemiripan Kalimat (Cosine Similarity)

Sebelum tahap pemodelan, representasi matriks TF-IDF dievaluasi menggunakan Cosine Similarity untuk mensimulasikan sistem temu kembali informasi (Information Retrieval). Pengujian dilakukan dengan query "anggaran program makan gratis terlalu besar", dan hasilnya berhasil menarik dokumen yang paling relevan secara leksikal, dengan skor similaritas tertinggi mencapai 0,5238 terhadap komentar "Anggaran negara untuk program MBG 335 triliun/tahun". Hasil ini menunjukkan bahwa representasi TF-IDF berhasil menangkap kedekatan makna leksikal antara query dan dokumen tanpa memerlukan anotasi label.

4.3 Representasi Teks (TF-IDF)

Representasi teks pada tahap pemodelan menggunakan TfidfVectorizer dengan kombinasi parameter max_features=1500 dan perluasan rentang n-gram (1, 2) yaitu kombinasi unigram dan bigram. Pada tahap preprocessing awal (5.035 baris data), konfigurasi ini menghasilkan representasi matriks renggang (sparse matrix) berukuran 5.035 baris dan 1.500 kolom fitur konseptual, sedangkan pada tahap pemodelan akhir vektorisasi dilakukan ulang terhadap subset 450 data berlabel yang telah digabungkan dengan fitur aspek hasil deteksi kata kunci.

4.4 Pemodelan ABSA dan NER

Data berlabel (450 sampel) dipecah menjadi data latih (80%) dan data uji (20%) secara stratified agar proporsi ketiga kelas sentimen tetap seimbang pada kedua subset. Data latih kemudian digunakan untuk melatih empat algoritma klasifikasi, yaitu SVM (kernel linear), Random Forest (100 estimator), Multinomial Naive Bayes, dan Logistic Regression, dengan pengaturan probability=True pada SVM agar dapat menghasilkan skor probabilitas untuk kebutuhan visualisasi dashboard. Sementara itu, pemodelan NER dilakukan berbasis pencocokan token (token-matching) terhadap kamus entities_dict untuk menghasilkan berkas ner_bio_dataset.tsv dalam format BIO Tagging.

BAB 5

HASIL DAN EVALUASI

5.1 Metrik ABSA dan Temuan Komparatif

Pengujian eksperimental dilakukan pada 90 data uji (20% dari 450 data berlabel) untuk keempat algoritma klasifikasi. Hasil pengujian menunjukkan temuan yang menarik dari sudut pandang kualitas data: pada dataset in-the-wild yang tidak dikurasi ini, Random Forest tampil sebagai model dengan akurasi tertinggi, sementara SVM justru menempati posisi terendah. Tabel 5.1 merangkum akurasi keseluruhan dari setiap model.

No	Model	Akurasi
1	Random Forest Classifier	62,22%
2	Multinomial Naive Bayes	61,11%
3	Logistic Regression	60,00%
4	Support Vector Machine (SVM)	58,89%

Tabel 5.1 Perbandingan Akurasi Model Klasifikasi Sentimen


Selisih akurasi antar model tergolong tidak terlalu besar (rentang sekitar 3,3 poin persentase), namun urutan performa ini konsisten dengan hipotesis awal penelitian: algoritma berbasis ensemble (Random Forest) yang mengandalkan mekanisme voting mayoritas dari banyak pohon keputusan cenderung lebih toleran terhadap label yang keliru pada sebagian kecil data latih, dibandingkan SVM yang posisinya sebagai pemisah hyperplane sangat dipengaruhi oleh titik-titik data individual di sekitar batas antar kelas. Perlu dicatat bahwa akurasi keseluruhan model masih berada pada kisaran 58-62%, yang menunjukkan bahwa noise label pada dataset asli memberi batas atas (upper bound) yang cukup rendah terhadap performa seluruh model, terlepas dari algoritma yang dipilih.

Berikut disajikan classification report lengkap untuk setiap model berdasarkan output eksperimen:

5.1.1 SVM (Support Vector Machine)

Kelas	Precision	Recall	F1-Score	Support
negative	0,65	0,73	0,69	30
neutral	0,54	0,43	0,48	30


Kelas	Precision	Recall	F1-Score	Support
positive	0,56	0,60	0,58	30
accuracy			0,59	90
macro avg	0,58	0,59	0,58	90
weighted avg	0,58	0,59	0,58	90



Confusion Matrix - SVM (Support Vector Machine)

5.1.2 Random Forest


Kelas	Precision	Recall	F1-Score	Support
negative	0,63	0,63	0,63	30
neutral	0,57	0,70	0,63	30
positive	0,70	0,53	0,60	30
accuracy			0,62	90
macro avg	0,63	0,62	0,62	90
weighted avg	0,63	0,62	0,62	90



Confusion Matrix - Random Forest

5.1.3 Multinomial Naive Bayes


Kelas	Precision	Recall	F1-Score	Support
negative	0,68	0,77	0,72	30
neutral	0,57	0,40	0,47	30
positive	0,57	0,67	0,62	30
accuracy			0,61	90
macro avg	0,61	0,61	0,60	90
weighted avg	0,61	0,61	0,60	90



Confusion Matrix - Multinomial Naive Bayes

5.1.4 Logistic Regression

Kelas	Precision	Recall	F1-Score	Support
negative	0,63	0,73	0,68	30
neutral	0,57	0,43	0,49	30
positive	0,59	0,63	0,61	30
accuracy			0,60	90
macro avg	0,60	0,60	0,59	90
weighted avg	0,60	0,60	0,59	90



Confusion Matrix - Logistic Regression

Secara umum, keempat classification report di atas memperlihatkan pola yang konsisten: kelas Netral memiliki F1-Score terendah pada hampir seluruh model, karena batasan antara opini netral dan opini yang cenderung positif/negatif secara implisit paling rentan terhadap perbedaan interpretasi subjektif pemberi label asli. Sebaliknya, kelas Negatif relatif paling mudah dikenali oleh seluruh model, ditunjukkan oleh recall yang lebih tinggi pada kelas tersebut.

5.2 Metrik NER (Token-Level)

Evaluasi pendekatan Rule-Based NER dilakukan pada level token terhadap keseluruhan hasil BIO Tagging (8.135 token). Perlu ditegaskan bahwa dataset ini tidak memiliki anotasi

Ground Truth NER hasil anotasi manusia secara independen; classification report pada bagian ini dihasilkan dari sebuah simulasi, yaitu dengan menyuntikkan gangguan (noise) acak sebesar 12% pada label yang seharusnya menjadi entitas (mengubahnya menjadi tag O) dan 2% pada label O (mengubahnya menjadi B-ASPECT), sebagai representasi kasar dari potensi kesalahan yang mungkin terjadi pada sistem kamus statis. Dengan demikian, angka pada Tabel 5.2 sebaiknya dibaca sebagai ilustrasi metodologis mengenai cara mengevaluasi sistem NER pada level token, bukan sebagai bukti akurasi tervalidasi dari sistem Rule-Based NER yang sesungguhnya. Evaluasi yang valid terhadap performa nyata sistem ini memerlukan anotasi Ground Truth manual oleh manusia sebagai pembanding, yang menjadi salah satu rencana pengembangan lanjutan (lihat Bab 8.3).

Tag	Precision	Recall	F1-Score	Support
B-ASPECT	0,86	0,76	0,81	521
B-LOC	0,85	1,00	0,92	53
B-ORG	0,93	1,00	0,96	78
B-PER	0,83	1,00	0,90	76
I-ASPECT	0,88	1,00	0,93	254
I-LOC	1,00	1,00	1,00	1
I-ORG	0,92	1,00	0,96	11
I-PER	0,75	1,00	0,86	6
O	0,98	0,98	0,98	7135
accuracy			0,97	8135
macro avg	0,89	0,97	0,93	8135
weighted avg	0,97	0,97	0,97	8135

Tabel 5.2 Simulasi Classification Report Token-Level Rule-Based NER

Meski bersifat simulatif, pola yang muncul tetap relevan untuk dibahas: skor precision B-ORG dan I-LOC yang tinggi mengindikasikan bahwa kamus entitas untuk kategori organisasi dan lokasi relatif lebih spesifik dan jarang tumpang tindih dengan kata umum, sedangkan skor precision B-ASPECT yang relatif lebih rendah (0,86) mengindikasikan bahwa kata-kata pada kamus ASPECT (seperti "menu", "makan", "gizi") lebih rentan muncul dalam konteks umum yang bukan merupakan aspek spesifik dari kebijakan MBG.

5.3 Confusion Matrix

Confusion Matrix untuk keempat model klasifikasi telah disajikan pada Sub-bab 5.1 (Gambar 5.1 - 5.4) sebagai bagian dari classification report masing-masing model.

5.4 Analisis Kesalahan (Error Analysis)

Sistem menyoroti sejumlah kasus di mana kegagalan prediksi model kemungkinan besar disebabkan oleh kualitas label Ground Truth dari dataset pihak ketiga (Kaggle), bukan sepenuhnya kegagalan matematis algoritma.

Kasus 1

Teks: "Utk ibu hamil dan balita bekerja sama lah dgn bgn posyandu yg sdh mberi mknan tambahan pd balita..."

Label Aktual (Kaggle): Netral | Prediksi Model: Positif

Analisis: Secara semantik, kalimat ini bermuatan konstruktif karena membahas kerja sama program gizi untuk ibu hamil dan balita. Prediksi model (Positif) sebenarnya masuk akal secara linguistik, namun dianggap salah karena pelabelan awal pada dataset Kaggle mengategorikannya sebagai Netral.

Kasus 2

Teks: "MBG knp tdk memanfaatkan kantin2 sekolah saja, agar tdk terbuang anggaran sewa dapur..."

Label Aktual (Kaggle): Netral | Prediksi Model: Negatif

Analisis: Kalimat tersebut mengandung kritik implisit terhadap potensi pemborosan anggaran sewa dapur. Model mendeteksi muatan negatif pada kritik tersebut, namun kembali berbenturan dengan label asli yang cenderung subjektif dari sudut pandang anotator dataset.


Kedua kasus di atas memperkuat argumen bahwa sebagian kesalahan klasifikasi pada penelitian ini bukan murni kegagalan algoritma, melainkan konsekuensi dari keputusan metodologis untuk tidak melakukan kurasi label secara manual.

BAB 6

IMPLEMENTASI APLIKASI

Bab ini menjelaskan implementasi model ke dalam sebuah aplikasi interaktif berbasis web menggunakan framework Streamlit, sehingga hasil riset pada Bab 4 dan Bab 5 dapat diakses dan diuji langsung oleh pengguna akhir. [Catatan: bagian ini merupakan kerangka. Silakan lengkapi dengan tangkapan layar (screenshot) aplikasi, penjelasan alur penggunaan yang sesuai dengan implementasi aktual, dan detail teknis lain sesuai aplikasi yang telah dibangun.]

6.1 Arsitektur dan Alur Sistem




6.2 Antarmuka dan Alur Pengguna

Aplikasi di-deploy secara lokal (localhost) menggunakan framework Streamlit. Pengguna dapat memasukkan teks ulasan pada elemen Text Area. Model yang telah diekspor sebelumnya (seperti `random_forest_model.joblib`, `svm_model.joblib`, `naive_bayes_model.joblib`, `logistic_regression_model.joblib`, dan `tfidf_vectorizer.joblib`) dipanggil kembali secara efisien menggunakan dekorator cache Streamlit tanpa perlu melakukan pelatihan ulang.



6.3 Fitur Luaran Interaktif

- Highlight Tagging: entitas hasil deteksi NER dicetak tebal dengan sorotan warna dinamis (kategori Aspek, Tokoh, Organisasi, dan Lokasi masing-masing dengan warna berbeda).
- Dashboard Probabilitas: visualisasi bar chart komparatif untuk keempat model secara berdampingan, menampilkan tingkat keyakinan (confidence score) masing-masing model terhadap kelas sentimen yang diprediksi.



6.4 Keterbatasan Sistem

Berdasarkan temuan di lapangan, aplikasi sangat bergantung pada kualitas kamus statis yang telah didefinisikan. Kata singkatan ekstrem dan bahasa slang harian yang berada di luar kosakata (Out-of-Vocabulary) akan dilewati begitu saja oleh sistem Rule-Based NER, karena pendekatan ini tidak memiliki kemampuan generalisasi seperti model berbasis pembelajaran kontekstual.

BAB 7

PEMETAAN OBE (OUTCOME BASED EDUCATION)

7.1 Ketercapaian CPL10

Berdasarkan Rancangan Penilaian Pembelajaran UAS Mata Kuliah Pemrosesan Bahasa Alami Berbasis Teks, seluruh soal UAS dipetakan pada satu Capaian Pembelajaran Lulusan (CPL), yaitu CPL10: “Mampu merancang, mengimplementasikan, dan mengevaluasi solusi berbasis sistem cerdas sesuai kebutuhan pengguna, perkembangan ilmu pengetahuan, dan praktik komputasi modern.”

Proyek Analisis Sentimen Berbasis Aspek (ABSA) dan Named Entity Recognition (NER) pada opini masyarakat terkait program Makan Bergizi Gratis memvalidasi ketercapaian CPL10 secara menyeluruh. Tahap perancangan (identifikasi masalah, pemilihan domain data YouTube, dan rancangan alur sistem) menunjukkan kemampuan merancang solusi sesuai kebutuhan pengguna; tahap implementasi (pipeline preprocessing, ekstraksi entitas berbasis aturan, dan pemodelan klasifikasi sentimen dengan empat algoritma) menunjukkan kemampuan mengimplementasikan sistem cerdas; dan tahap evaluasi (confusion matrix, classification report, serta error analysis pada Bab 5) menunjukkan kemampuan mengevaluasi solusi secara terukur dan dapat dipertanggungjawabkan, sejalan dengan praktik komputasi modern berbasis data dunia nyata (in-the-wild).

7.2 Pemenuhan Sub-CPMK per Klaster

Sesuai Tabel 1 (Mapping Klaster Sub-CPMK UAS terhadap CPL Prodi) pada Lembar Soal Ujian, penilaian UAS dikelompokkan ke dalam empat klaster Sub-CPMK, yaitu Klaster A, B, C, dan D. Tabel 7.1 berikut memetakan capaian proyek ini terhadap keempat klaster tersebut.

Klaster Sub-CPMK	Deskripsi	Bukti Capaian pada Proyek
Klaster A (Sub-CPMK 10.1.1-10.1.4)	Fondasi NLP, konsep bahasa, FSA/regex, dan preprocessing	Terpenuhi melalui latar belakang dan rasional project (Bab 1), penjelasan konsep NLP (Bab 2), serta implementasi 4 fungsi regular expression dan pipeline preprocessing lengkap (case folding, cleaning URL/mention, normalisasi slang, stopword removal, stemming Sastrawi) pada Bab 4.1
Klaster B (Sub-CPMK 10.1.5-10.1.6)	Representasi teks, term weighting, edit distance, dan similarity	Terpenuhi melalui representasi TF-IDF dengan kombinasi unigram-bigram (Bab 2.2 dan 4.3), perhitungan Minimum Edit Distance untuk normalisasi typo (Bab 4.1), serta Cosine Similarity untuk pengukuran kemiripan kalimat/review (Bab 4.2)
Klaster C (Sub-CPMK 10.1.7-10.1.12)	Machine learning, evaluasi model, word embedding, deep learning, dan clustering	Terpenuhi melalui pembangunan dan perbandingan empat algoritma supervised learning (Random Forest, Multinomial Naive Bayes, Logistic Regression, SVM) pada Bab 4.4, serta evaluasi model lengkap menggunakan confusion matrix, accuracy, precision, recall, dan F1-score pada Bab 5.1
Klaster D (Sub-CPMK 10.1.13-10.1.14)	NER, BIO tagging, POS/HMM, integrasi ABSA, dan aplikasi UI/UX	Terpenuhi melalui perancangan skema entitas ASPECT/PER/ORG/LOC dan implementasi Rule-Based NER dengan format BIO Tagging (Bab 3.4 dan 4.4), evaluasi token-level NER (Bab 5.2), serta integrasi ABSA dan NER ke dalam aplikasi Streamlit interaktif (Bab 6)

Tabel 7.1 Pemetaan Capaian Proyek terhadap Klaster Sub-CPMK UAS

Dengan demikian, proyek ini memenuhi keempat klaster Sub-CPMK yang disyaratkan, mulai dari fondasi NLP (Klaster A) hingga integrasi NER dan ABSA dalam aplikasi UI/UX yang dapat diuji pengguna (Klaster D), sekaligus menjawab kelima soal UAS (Soal 01-05) yang telah dipetakan pada Tabel 2 Lembar Soal Ujian.

7.3 Keterkaitan dengan Materi Perkuliahan (14 Modul PBA)

Daftar Materi/Pilihan Modul yang Dapat Diintegrasikan ke Project (Lembar Soal Ujian, halaman 3) memuat 14 materi NLP yang dapat dipilih mahasiswa untuk diintegrasikan ke dalam proyek, dengan syarat minimal 6 materi terpenuhi secara eksplisit. Tabel 7.2 berikut merangkum keterkaitan proyek ini dengan keempat belas materi tersebut.

No	Materi NLP	Diimplementasikan	Bukti pada Proyek
1	Pengantar NLP	Ya	Dijelaskan sebagai latar belakang dan rasional project pada Bab 1.1 dan 1.4 (posisi pipeline rule-based, statistik, dan supervised learning dalam PBA)
2	Konsep bahasa	Sebagian	Disinggung pada Bab 2.5 melalui konsep token dan entitas untuk NER; morfologi/sintaksis tidak dibahas mendalam karena fokus proyek pada jalur statistik-rule-based
3	FSA & Regular Expression	Ya	Diimplementasikan sebagai 4 fungsi regex untuk pembersihan HTML, URL, mention/hashtag, dan karakter non-alfabet (Bab 4.1)
4	Text Processing	Ya	Diimplementasikan lengkap: case folding, normalisasi slang/typo, stopword removal, dan stemming Sastrawi (Bab 2.1 dan 4.1)
5	Representasi Teks	Ya	Diimplementasikan melalui TF-IDF dengan kombinasi unigram-bigram, max_features=1500 (Bab 2.2 dan 4.3)
6	Similarity	Ya	Diimplementasikan melalui Minimum Edit Distance untuk normalisasi typo dan Cosine Similarity untuk kemiripan kalimat (Bab 2.1 dan 4.2)
7	KNN untuk NLP	Tidak	Tidak digunakan sebagai baseline; proyek berfokus pada perbandingan Random Forest, Naive Bayes, Logistic Regression, dan SVM
8	Naive Bayes untuk NLP	Ya	Diimplementasikan sebagai salah satu dari empat model pembanding ABSA

			(Multinomial Naive Bayes), lihat Bab 2.3 dan 5.1.3
9	Evaluasi Model	Ya	Diimplementasikan lengkap melalui confusion matrix, accuracy, precision, recall, dan F1-score untuk seluruh model ABSA serta NER (Bab 2.4, 5.1, dan 5.2)
10	Word Embedding	Tidak	Belum diimplementasikan; direncanakan sebagai pengembangan lanjutan (Bab 8.3)
11	Neural Network/Deep Learning	Tidak	Belum diimplementasikan; transisi ke model terkontekstualisasi (IndoBERT) diusulkan sebagai rencana pengembangan (Bab 8.3)
12	Clustering Teks	Tidak	Tidak digunakan karena proyek berbasis supervised learning dengan label sentimen yang sudah tersedia
13	Named Entity Recognition	Ya	Diimplementasikan sebagai modul Rule-Based NER dengan skema entitas ASPECT, PER, ORG, dan LOC (Bab 3.4 dan 4.4)
14	BIO Tagging & POS/HMM	Ya	BIO tagging diimplementasikan penuh pada ner_bio_dataset.tsv (Bab 4.4); POS/HMM dijelaskan secara konseptual sebagai rencana pengembangan lanjutan

Tabel 7.2 Keterkaitan Proyek dengan 14 Materi/Modul Perkuliahan PBA

Berdasarkan Tabel 7.2, proyek ini secara eksplisit mengimplementasikan 9 dari 14 materi kuliah yang disediakan, yaitu Pengantar NLP, FSA & Regular Expression, Text Processing, Representasi Teks, Similarity, Naive Bayes untuk NLP, Evaluasi Model, Named Entity Recognition, serta BIO Tagging. Jumlah ini telah melampaui syarat minimal 6 dari 14 materi yang disyaratkan pada Lembar Soal Ujian halaman 3, sehingga proyek ini memenuhi ketentuan pemetaan materi kuliah terhadap prinsip Outcome Based Education (OBE).

BAB 8

KESIMPULAN

8.1 Capaian Penelitian

Penelitian ini berhasil mengeksekusi pipeline NLP secara menyeluruh, mulai dari preprocessing teks, ekstraksi entitas berbasis aturan, hingga klasifikasi sentimen komparatif dengan empat algoritma. Eksperimen menunjukkan bahwa Random Forest (62,22%) merupakan algoritma dengan akurasi tertinggi dan daya tahan yang relatif lebih baik dibandingkan SVM (58,89%) ketika dihadapkan pada dataset berdimensi besar (TF-IDF bigram) yang masih mengandung struktur label bising (noise label) tanpa proses kurasi manual, meski selisih akurasi antar model tergolong tidak terlalu besar.

8.2 Pembelajaran Utama (Lessons Learned)

Pelajaran paling mendasar dari proyek ini adalah relevannya prinsip "Garbage In, Garbage Out" dalam praktik. Hal ini terlihat jelas pada hasil Error Analysis, di mana performa metrik akurasi cenderung tertahan pada kisaran 58-62% meskipun representasi fitur (TF-IDF bigram) dan algoritma klasifikasi yang digunakan sudah cukup memadai. Hal ini mengindikasikan bahwa label acuan dasar (Ground Truth) dari sumber data (Kaggle) yang bersifat subjektif dan tidak dikurasi turut membatasi performa maksimum yang dapat dicapai oleh model, terlepas dari algoritma yang dipilih.

8.3 Rencana Pengembangan Lanjutan

Sebagai tahapan iterasi ke depan, terdapat beberapa pembaruan arsitektural dan metodologis yang disarankan:

6. Kurasi Label dengan Active Learning: memanfaatkan pelabelan oleh ahli independen atau pendekatan semi-supervised learning untuk membersihkan dataset dari noise subjektif sebelum dilatih, sehingga upper bound performa model dapat ditingkatkan.
7. Anotasi Ground Truth NER Manual: melakukan anotasi manual oleh manusia terhadap sebagian data untuk mendapatkan evaluasi performa Rule-Based NER yang benar-benar valid, menggantikan simulasi noise yang digunakan pada Bab 5.2.

8. Transisi ke Model Terkontekstualisasi: menggantikan kamus Rule-Based dengan model bahasa terkontekstualisasi seperti IndoBERT (Indonesian RoBERTa) yang memiliki mekanisme self-attention untuk memahami ambiguitas dan struktur tata bahasa secara implisit, sehingga tidak lagi bergantung pada kamus statis yang rentan terhadap kata di luar kosakata (Out-of-Vocabulary).

DAFTAR PUSTAKA

Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5-32.

Sastrawi Contributors. (2018). Sastrawi: Simple Indonesian stemming and stopword removal library. GitHub Repository.

Scikit-learn Developers. (2024). scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*.